



REDES NEURONALES



Facultad de Ciencias



Universidad Nacional Autónoma de México



Tarea No. 02

Realizado por:

Iván Alejandro Ramos Herrera



[@arhcoder](#)

▼ [01]



Demostrar que bajo un conjunto de pesos $\theta^* = \{w^*, b^*\}$ el perceptrón y la regresión logística son clasificadores binarios equivalentes:

Definiciones

Definición del Perceptrón:

$$f_p(x) = \text{sign}(w^*x + b^*)$$

Es decir...

$$f_p(x) = \begin{cases} 1 & \text{si } w^*x + b^* > 0 \\ 0 & \text{si } w^*x + b^* \leq 0 \end{cases}$$

Donde:

- x vector de entradas en \mathbb{R}^d
- w^* es un vector de pesos en \mathbb{R}^d
- b^* es el valor de sesgo.

Definición de la Regresión Logística:

$$f_r(x) = \sigma(w^*x + b^*)$$

Es decir..

$$f_r(x) = P(y = 1|x)$$

$$f_r(x) = \frac{1}{1 + e^{-(w^*x + b^*)}}$$

En donde para una clasificación binaria **(0, 1)**:

$$f_r(x) = \begin{cases} 1 & \text{si } P(y = 1|x) \geq 0.5 \\ 0 & \text{si } P(y = 1|x) < 0.5 \end{cases}$$

Donde:

- x vector de entradas en \mathbb{R}^d
- w^* es un vector de pesos en \mathbb{R}^d
- b^* es el valor de sesgo.

Demostración

¿Bajo un mismo conjunto de pesos θ , ambos clasificadores tomarán las mismas decisiones?

$$w^*x + b^* = P(y = 1|x) - 0.5$$

Simplificando las definiciones:

$$f_p(x) = \begin{cases} 1 & \text{si } w^*x + b^* > 0 \\ 0 & \text{en cualquier otro caso} \end{cases}$$

$$f_r(x) = \begin{cases} 1 & \text{si } P(y = 1|x) \geq 0.5 \\ 0 & \text{en cualquier otro caso} \end{cases}$$

Si se demuestra que se clasifica como 1 en los dos primeros casos de cada función, se deduce que también se clasificará 0 (en cualquier otro caso), por lo que sólo basta con demostrar la equivalencia con las clasificaciones de 1.

Demostrando equivalencia con los casos:

- $w^*x + b^* > 0$
- $P(y = 1|x) \geq 0.5$

$$P(y = 1|x) \geq 0.5 = w^*x + b^* > 0$$

∴

$$\frac{1}{1+e^{-(w^*x+b^*)}} \geq 0.5$$

Resolviendo la desigualdad:

Pasar multiplicando el denominador:

$$1 \geq 0.5(1 + e^{-(w^*x+b^*)})$$

$$1 \geq 0.5 + 0.5e^{-(w^*x+b^*)}$$

Pasando el 0.5 al lado izquierdo:

$$1 - 0.5 \geq 0.5e^{-(w^*x+b^*)}$$

$$0.5 \geq 0.5e^{-(w^*x+b^*)}$$

Eliminando el 0.5:

$$1 \geq e^{-(w^*x+b^*)}$$

Eliminando e con \ln :

$$\ln(1) \geq -(w^*x + b^*)$$

$$0 \geq -(w^*x + b^*)$$

Eliminando el signo invirtiendo la desigualdad:

$$0 \leq w^*x + b^*$$

Esto es igual al caso en el perceptrón:

$$w^*x + b^* > 0$$

\therefore

$f_p = f_r$ con $\theta^* = \{w^*, b^*\}$ bajo las definiciones descritas.

El Modelo de Perceptrón con Función Escalonada y la Regresión Logística son equivalentes bajo la definición de clasificación binaria.

▼ [02]

 Definir una Red Neuronal que obtenga cada una de las siguientes funciones de \mathbb{R}^2 a \mathbb{R} :

1. $f(x, y) = xy$


2. $f(x, y) = xy + \frac{x}{y}$

3. $f(x, y) = 2x^2 + 2xy$

4. $f(x, y) = x^2 + 2xy + y^2$

▼ xy :

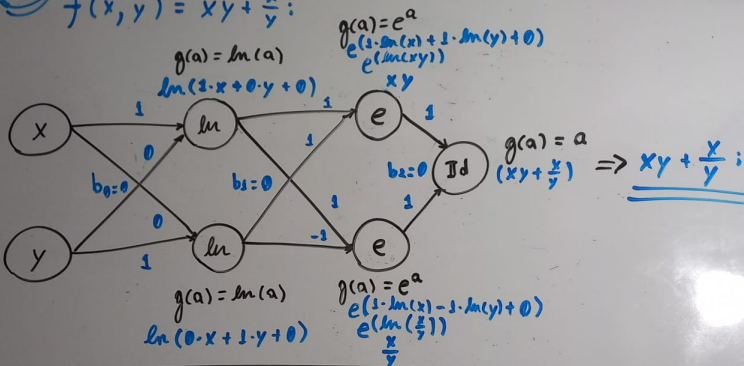
① $f(x, y) = xy$:



$w_0 = \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix}; w_1 = \begin{bmatrix} 1 & 1 \end{bmatrix};$
 $b_0 = 0; b_1 = 0;$

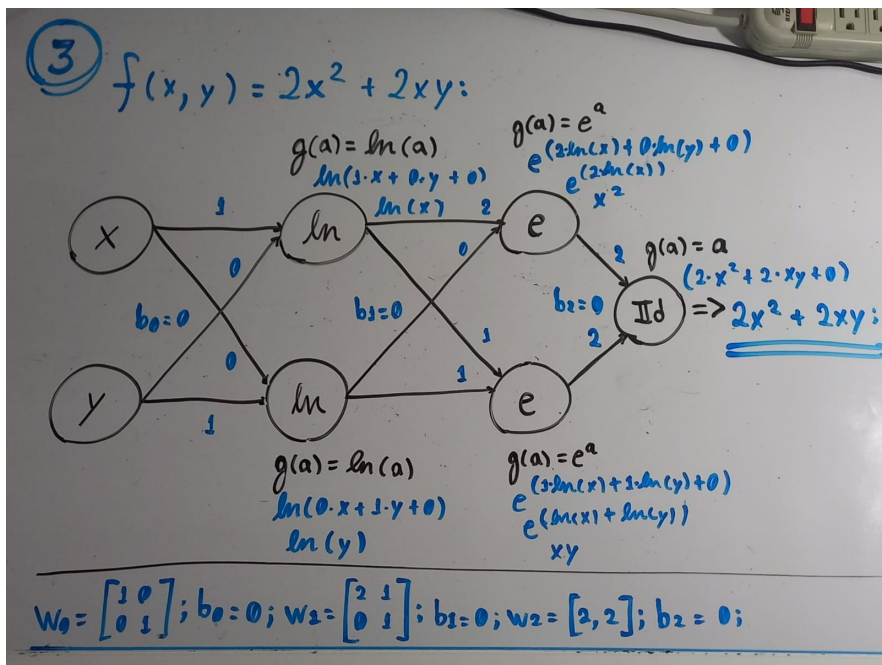
▼ $xy + \frac{x}{y}$:

② $f(x, y) = xy + \frac{x}{y}$:

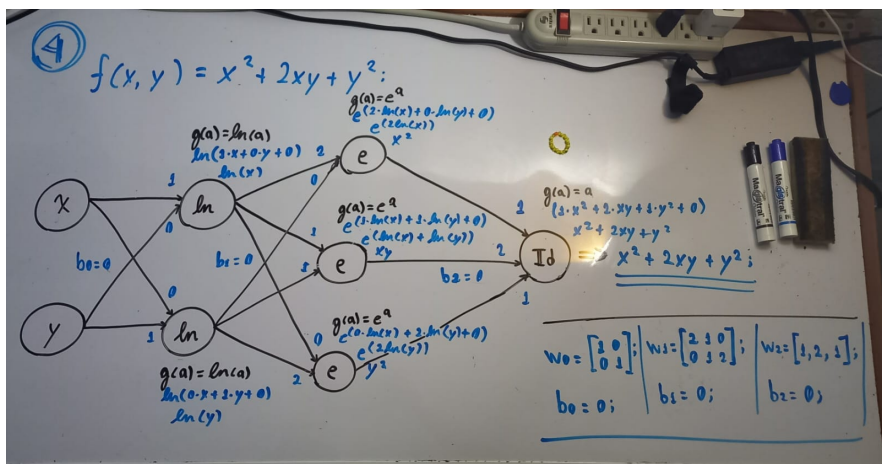


$w_0 = \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix}; w_1 = \begin{bmatrix} 1 & 1 \\ 1 & -1 \end{bmatrix}; w_2 = \begin{bmatrix} 1 & 1 \end{bmatrix};$
 $b_0 = 0; b_1 = 0; b_2 = 0;$

▾ $2x^2 + 2xy$:



▾ $x^2 + 2xy + y^2$:



▼ [03]

✨ Realizar el proceso de derivación para las funciones;

- Sigmoide
- Tangente Hiperbólica
- Softplus

▼ Sigmoide derivada

Derivación:

$$\underline{1.} \quad \sigma(x) = \frac{1}{1+e^{-x}};$$

$$\frac{\delta \sigma(x)}{\delta x} = \frac{\delta}{\delta x} \left(\frac{1}{1+e^{-x}} \right);$$

$$= \frac{\delta (1+e^{-x})^{-1}}{\delta x};$$

$$= \frac{1}{\delta x} (1+e^{-x})^{-2};$$

Regla de recíproco:

$$\frac{\delta}{\delta x} (u(x)^{-1}) = - \left[\frac{\frac{\delta}{\delta x} (u(x))}{(u(x))^2} \right];$$

$$= -u(x)^{-2} \cdot \frac{\delta}{\delta x} u(x);$$

$$\therefore \frac{\delta}{\delta x} (1+e^{-x})^{-1} = - (1+e^{-x})^{-2} \cdot \frac{\delta}{\delta x} (1+e^{-x});$$

$$\frac{\delta}{\delta x} [a \cdot u(x) + b \cdot v(x)] = a \cdot \frac{\delta}{\delta x} u(x) + b \cdot \frac{\delta}{\delta x} v(x);$$

$$\therefore (1+e^{-x})^{-2} \left[\frac{\delta}{\delta x} (1) + \frac{\delta}{\delta x} (e^{-x}) \right];$$

$$= - (1+e^{-x})^{-2} \cdot \left(\frac{\delta}{\delta x} e^{-x} \right);$$

$$= - (1+e^{-x})^{-2} \cdot (e^{-x} \cdot (-1));$$

$$= - (1+e^{-x})^{-2} \cdot (-e^{-x});$$

$$= \frac{e^{-x} \cdot (1+e^{-x})^{-2}}{(1+e^{-x})^2};$$

$$= \frac{e^{-x}}{(1+e^{-x})^2};$$

$$= \frac{1}{(1+e^{-x})} \cdot \frac{e^{-x}}{(1+e^{-x})};$$

$$= \frac{1}{1+e^{-x}} \cdot \left(\frac{1+e^{-x}}{1+e^{-x}} - \frac{1}{1+e^{-x}} \right);$$

$$= \frac{1}{\sigma(x)} \cdot \left(1 - \frac{1}{\sigma(x)} \right);$$

$$\therefore \frac{\delta \sigma(x)}{\delta x} = \sigma(x) \cdot (1 - \sigma(x));$$

▼ Tangente Hiperbólica derivada

Derivación:

$$\underline{2.} \quad \tanh(x) = \frac{e^x - e^{-x}}{e^x + e^{-x}};$$

$$\frac{\delta \tanh(x)}{\delta x} = \frac{\delta}{\delta x} \left(\frac{e^x - e^{-x}}{e^x + e^{-x}} \right);$$

$$= \frac{\delta}{\delta x} [(e^x - e^{-x})(e^x + e^{-x})^{-1}];$$

Regla del producto:

$$= \left[\frac{\delta}{\delta x} (e^x - e^{-x}) \right] (e^x + e^{-x})^{-1} + \left[\frac{\delta}{\delta x} (e^x + e^{-x})^{-1} \right] (e^x - e^{-x});$$

a) $\frac{e^x + e^{-x}}{e^x + e^{-x}} \Rightarrow 1$; 3a;

b) Regla de la cadena:

$$= \frac{\delta g(x)}{\delta x} g(x)^{-1} \cdot \frac{\delta}{\delta x} (e^x + e^{-x});$$

$$= -1 \cdot g(x)^{-2} \cdot (e^x - e^{-x});$$

$$= -\frac{1}{g(x)^2} \cdot (e^x - e^{-x});$$

$$= -\frac{1}{(e^x + e^{-x})^2} \cdot (e^x - e^{-x});$$

$$= \frac{e^x - (-1 \cdot e^{-x})}{(e^x + e^{-x})^2} \cdot (e^x - e^{-x});$$

$$= 1 + \left(\frac{1}{e^x + e^{-x}} \right) (e^x - e^{-x});$$

$$= 1 - \frac{(e^x - e^{-x})(e^x - e^{-x})}{(e^x + e^{-x})^2};$$

$$= 1 - \frac{(e^x - e^{-x})^2}{(e^x + e^{-x})^2};$$

$$= 1 - \left[\frac{e^x - e^{-x}}{e^x + e^{-x}} \right] \left[\frac{e^x - e^{-x}}{e^x + e^{-x}} \right];$$

$$= 1 - [\tanh(x) \tanh(x)];$$

$$\therefore \frac{\delta \tanh(x)}{\delta x} = 1 - \tanh(x)^2;$$

▼ Softplus derivada

Derivación:

$$\underline{3. S(x) = \log(1 + e^x);}$$

$$\frac{\delta S(x)}{\delta x} = \frac{\delta}{\delta x} (\log(1 + e^x));$$

$$\frac{\delta S(x)}{\delta x} = \frac{\delta}{\delta x} (\ln(1 + e^x));$$

Considerando $\log(1 + e^x)$
como $\ln(1 + e^x)$;

$$= \frac{1}{e^x + 1} \cdot \frac{\delta}{\delta x} (e^x + 1);$$

$$= \frac{\frac{\delta}{\delta x} e^x + \cancel{\frac{\delta}{\delta x} 1}}{e^x + 1};$$

$$= \frac{\frac{\delta}{\delta x} e^x}{e^x + 1};$$

$$= \frac{e^x}{e^x + 1};$$

$$\therefore \underline{\underline{\frac{\delta S(x)}{\delta x} = \frac{e^x}{e^x + 1};}}$$

▼ [04]

 Demostrar la identidad:

$$\frac{e^{a_i + c}}{\sum_j e^{a_j + c}} = \frac{e^{a_i}}{\sum_j e^{a_j}}$$

para cualquier constante arbitraria $c \in \mathbb{R}$:

▼ Demostración

$$\frac{e^{a_i + c}}{\sum_j e^{a_j + c}} = \frac{e^{a_i}}{\sum_j e^{a_j}}$$

Utilizando la propiedad:

$$e^{a+b} = e^a e^b$$

Factorizando:

$$\frac{e^{a_i} e^c}{\sum_j e^{a_j} e^c} = \frac{e^{a_i}}{\sum_j e^{a_j}}$$

$\frac{e^c}{e^c}$ se elimina...

$$\frac{e^{a_i} e^c}{\sum_j e^{a_j} e^c} = \frac{e^{a_i}}{\sum_j e^{a_j}}$$

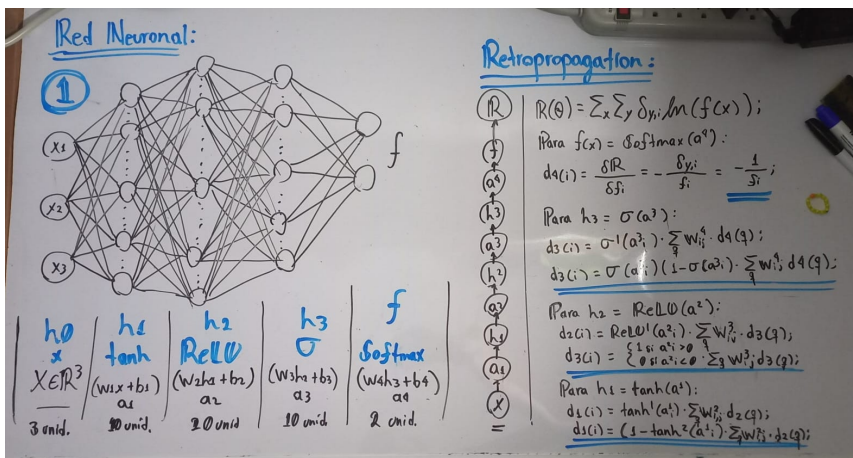
∴

$$\frac{e^{a_i}}{\sum_j e^{a_j}} = \frac{e^{a_i}}{\sum_j e^{a_j}}$$

▼ [05]

Utilizar el algoritmo de backpropagation para obtener las derivadas de la siguiente Red Neuronal:

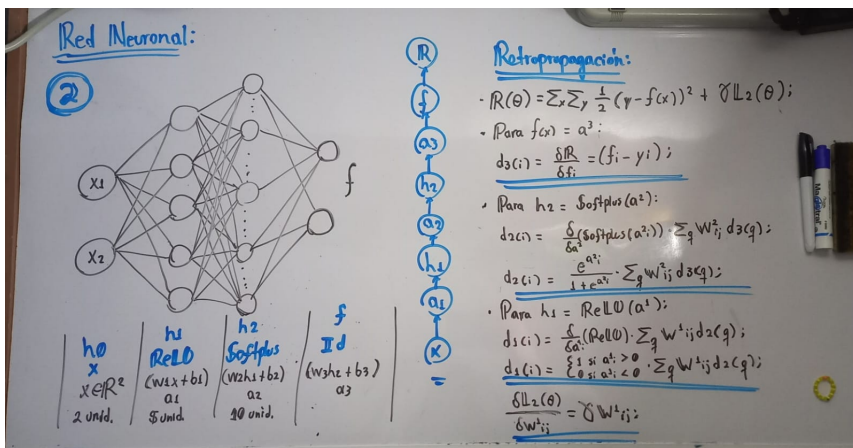
- Capa de entrada: $x \in \mathbb{R}^3$
- Primera capa: $h_1 = \tanh(W_1 x + b_1)$ con 10 unidades
- Segunda capa: $h_2 = \text{ReLU}(W_2 h_1 + b_2)$ con 20 unidades
- Tercera capa: $h_3 = \sigma(W_3 h_2 + b_3)$ con 10 unidades
- Capa de salida: $f(x) = \text{Softmax}(W_4 h_3 + b_4)$ con 2 unidades
- Función de riesgo: $R(\theta) = \sum_x \sum_y \delta_{y,i} \ln(f(x))$



▼ [06]

Usar el metodo de backpropagation para obtener las derivadas de la siguiente Red de regresión que utiliza regularización L_2 :

- Capa de entrada: $x \in \mathbb{R}^2$
- Primera capa: $h_1 = \text{ReLU}(W_1 x + b_1)$ con 5 unidades
- Segunda capa: $h_2 = \text{Softplus}(W_2 h_1 + b_2)$ con 10 unidades
- Capa de salida: $f(x) = W_3 h_2 + b_3$ con 2 unidades
- Función de riesgo: $R(\theta) = \sum_x \sum_y \frac{1}{2} (y - f(x))^2 + \gamma L_2(\theta)$



[08]

Realizado por:

Iván Alejandro Ramos Herrera



@arhocoder